

Red neuronal convolutiva (explicación)

La red neuronal convolutiva CNN (convolutional neural network) es una arquitectura de Deep Learning especializada en procesar datos con estructura de grilla, como las imágenes. A diferencia de una red simple, que aplanar la imagen en un vector y procesa cada pixel de forma separa , esta red aplica filtros (también conocidos como kernel) que se desplazan sobre la imagen para detectar patrones como bordes, curvas, texturas, etc., conservando la relación de vecindad entre pixeles y compartiendo parámetros entre distintas áreas de la imagen. Lo que conlleva a reducir significativamente el número de parámetros a entrenar y lo hace más eficiente, además de mucho menos propenso a sobreajuste.

La red neuronal se llama convolutiva ya que se basan en la operación matemática de la convolución aunque técnicamente las librerías de python hacen correlación cruzada.

A modo de ejemplo se muestra una red neuronal simple ANN, sin capa convolutiva compuesta con dos capas densa de 25 neuronas en cada capa, entrenada para reconocer los dígitos , en este caso no hay filtros que agrupe la información de los pixeles vecinos. Si accede a l enlace de la imagen puede ver a medida que se dibuja el trazo del número las actividades de las capas cambian.

https://www.linkedin.com/posts/alejandroadiaz_ann-ia-ia-activity-7271829470485897216-lvbL/?rcm=ACoAACtku0QBUtu9u0U196HM4UjX200tOluZI4




Figura 1. Ejemplo ilustrativo de una ANN para el mismo ejemplo propuesto del la prueba. Imagen obtenida de linkedin

La ventaja de una red neuronal convolutiva es que en vez de conectar cada pixel con todas las neuronas , gracias a la convolución se aprovecha la estructura espacial de la imagen para extraer patrones de los vecinos con menos parámetros y a medida que se va descomponiendo la imagen se abstraer más la información (como forma de embudo). El aprendizaje se da de forma jerarquizada, las primeras capas detectan patrones simples y las capas mas profundas combinan esos patrones para reconocer estructuras mas complejas

Componentes de una red neuronal convolutiva

1. Capa de convolución

Consta en aplicar filtro o kernel que se deslizan sobre la imagen de la entrada, calculando en cada posición un producto punto entre el filtro y la región de la imagen que esta cubriendo. Cada kernel se especializa en detectar distinto patrones, generando, así como salida un Mapa de características (feature map). Los parámetros importantes de esta capa son:

- Número de filtros
- Tamaño del kernel
- Paso de deslizamiento (stride)
- Relleno de bordes (padding).

Continuación de un ejemplo ilustrativo, de lo que genera un filtro con todos sus valores $1/9$ que se aplica sobre una región de 3×3 píxeles (matriz de 3×3 con $a_{ij} = 1/9$). La entrada es la imagen de la izquierda y la salida es la imagen de la derecha (que es el mapa de característica que genera dicho filtro). El efecto visual que genera este filtro (matriz de 3×3 con $a_{ij} = 1/9$) se le llama blur. (ver referencia libro)




Figura 2. Ejemplo filtro $1/9$ Imagen obtenida de video de youtube

Otro ejemplo con un filtro distinto es lo que se muestra en la siguiente imagen. El filtro es una matriz de 3×3 con $a_{i1} = -1$, $a_{i2} = 0$, $a_{i3} = 1$, que detecta bordes verticales.





Figura 3. Ejemplo filtro -1 0 1 Imagen obtenida de video de youtube

Cabe destacar que los filtros no se diseñan de forma manual, sus parámetros son aprendidos durante el entrenamiento.

Cada capa convolutiva aplica muchos filtros en paralelo, lo que conlleva a que a partir de solamente una imagen se obtienen varios mapas de característica, una por cada filtro.

Ejemplo de como el kernel recorre una imagen



Here we use the convention from [NND2](#), where indices begin at 1

Figure 8.2: Example Convolution Layout

Figura 4. Ejemplo de recorrido de un filtro. Imagen obtenida de libro

La siguiente imagen muestra una entrada de 200x200 pixeles con 3 canales de color que combina 16 filtros de matriz 7x7 lo que produce 16 mapas de característica




Figura 5. Ejemplo de capa convolucional. Imagen obtenida de video de youtube

Estos mapas de característica son tensores tridimensionales (tiene altoxanchoxcanales), se ven distintos según el objeto de la imagen de entrada, se deja ejemplo de dos imágenes distinta y sus mapas de característica.




Figura 6. Ejemplo de mapas de característica de una cebolla, Imagen obtenida de video de youtube




Figura 7. Ejemplo de mapas de característica de una manzana, Imagen obtenida de video de youtube

2. Función de activación

El paso siguiente después de la convolución es aplicar una función de activación no lineal, típicamente de tipo Relu (Rectified Linear Unit). Lo que hace es introducir no linealidad al modelo, lo que lleva a aprender relaciones más complejas y evita el problema de desvanecimiento del gradiente es por esta razón que no se recomienda usar una función de activación sigmoide o tangente hiperbólica.

3. Capa de agrupamiento

Reduce la dimensionalidad espacial de los mapas de característica, por ejemplo se pasa de 8x8 a 4x4 conservando la información más relevante, esto ayuda que se disminuya la cantidad de parámetros y el costo computacional de las siguientes capas y propicia invarianza ante pequeñas traslaciones o distorsiones del dígito.

4. Flatten (aplanar)

Convierte los mapas de característica en un vector unidimensional. Esto es necesario para conectar la información extraída por la capa convolutiva con capas densas que esta última se encarga de la clasificación final.

La siguiente imagen muestra el efecto de flatten




Figura 8. Ejemplo ilustrativo de flatten en imagen de dígito pixel. Imagen obtenida de video de youtube

5. Fully Connected(capa densa)

Las neuronas de la capa densa se conectan con todas las salidas de la capa anterior, lo que permite combinar las características extraídas para realizar la clasificación.

La última capa densa utiliza activación softmax que transforma las salidas en una distribución de probabilidad sobre las clases posibles que en este caso son 10 ya que son 10 dígitos lo que se analizan, donde la clase con mayor probabilidad es la predicción del modelo.

6. Dropout (regularización)

Técnica de regularización, que apaga aleatoriamente un porcentaje de neuronas en cada paso, esto evita que la red aprenda de neuronas específicas y reduce el sobreajuste, lo que lleva al modelo a aprender representaciones más generalizables.

Arquitectura típica de una CNN



Funcionamiento general del modelo de una Red neuronal convolutiva

Lo que sucede es que la imagen pasa secuencialmente por bloques de convolución +relu+pooling que extraen características cada vez más abstractas, luego el flatten y las capas densas combinan esas características para clasificar la imagen. Durante el entrenamiento, la predicción del modelo se compara con la etiqueta real mediante una función de pérdida y los pesos de la red se ajustan mediante retropropagación y un algoritmo de optimización (el que se allí seleccionado como por ejemplo Adam o SGD), se repite este proceso a lo largo de varias épocas hasta minimizar el error de clasificación.

Ejemplo básico de una red neuronal convolutiva




Figure 8.1: Basic Convolution Layer

Ejemplo de modelo de red neuronal con convolución y pooling (en este caso es un maxpooling que es el más usado)





Figure 8.9: Network with Convolution and Pooling Layers

Aplicaciones practica

- Detección autónoma de defecto sen la línea de producción industriales
- Detección de peatones en vehículos autónomos
- Conteo de huevos y detección de quebrado en la línea de producción (cuando hice mi practica en la empresa hicieron esto)
- Cámaras de seguridad detección de personas que se acercan al portón de una casa
- Reconocimiento facial
- Reconstrucción de imágenes, algo como se muestra en la imagen de a continuación



En conclusión, la principal ventaja de una red neuronal convolutiva por sobre una red neuronal simple (ANN) en el caso de aplicarse a una imagen, es que la CNN trabaja en base a la estructura espacial ya que conserva mediante los filtros que además comparten sus parámetros en toda la imagen, en cambio en un ANN la imagen se aplana y trata cada pixel de forma independiente.

En una CNN existen dos beneficios principales uno es la reducción en la cantidad de parámetros a entrenar y además una menor propensión al sobreajuste. Agrega que también existen un aprendizaje jerárquico donde las capas del comienzo detectan patrones simples y las capas profundas los combinan para reconocer estructurar aun mas complejas , algo que no sucede en una red simple. Es por esto que la CNN es ampliamente usada en tareas de visión computacional

Fuentes imágenes

- https://www.linkedin.com/posts/alejandroadiaz_ann-ia-ia-activity-7271829470485897216-lvbL?utm_source=share&utm_medium=member_desktop&rcm=ACoAACtku0QBUtu9u0U196HM4UiJx200tOluZI4, video sobre ANN para clasificación de dígitos.
- <https://www.youtube.com/watch?v=V8j1oENVz00> video sobre CNN en español.
- <https://github.com/NNDesignDeepLearning/NNDesignDeepLearning> [Texto en desarrollo github]